Una cota de Fano para representaciones reducidas en la decodificación de habla imaginada por electroencefalografía

César Uriel Ramírez-Trejo
Universidad Autónoma de Querétaro
Querétaro, México
cramirez08@alumnos.uaq.mx

Luis Felipe Estrella-Ibarra
Universidad Autónoma de Querétaro
Querétaro, México
efelipe2274@gmail.com

***Abstract*—La diversidad en las características de extracción de datos en datasets para decodificación del habla imaginada con electroencefalografía no permite vislumbrar entre las ventajas y oportunidades de trabajar con cada uno. Este trabajo pretende implementar una primera aproximación en la construcción de una cota superior del desempeño de clasificadores que operan sobre una representación reducida de la señal (un canal, un instante o la instancia completa tras PCA), así como proponer la Cota de Fano-Confound (CFC), un estadístico descriptivo que contrasta la información de clase con la de la identidad del sujeto. En cinco conjuntos públicos, la identidad del sujeto resulta casi perfectamente recuperable, mientras que la información de clase es, en todos los casos más modesta que la de sujeto.**

***Index Terms*—Decodificación del habla imaginada, machine learning, cota de Fano, confound, estimador Kraskov-Stögbauer-Grassberger, información mutua.**

I. Introducción

Se ha encontrado que parte de la investigación en Inteligencia Artificial privilegia la mejora empírica del desempeño por encima de la explicación y el análisis riguroso de sus causas [1]; de acuerdo con la ley de Goodhart [2], [3], toda medida deja de ser confiable cuando se convierte en objetivo, razón que pone en la mesa la necesidad de cuestionarse la manera en que son desarrolladas estas tecnologías.

Existen diversos modelos de IA dedicados a la decodificación del habla imaginada por electroencefalografía (EEG) y electrocorticografía (ECoG) entrenados con datasets de diferentes características: canales del dispositivo, frecuencia de muestreo, cantidad de fonemas, categoría fonética, número de sujetos, sesiones, lenguaje, condiciones de captura. Es necesario homologar la complejidad de la clasificación; este estudio intenta cuantificar la dificultad de clasificar datasets basado en la información contenida en el propio dataset y de forma independiente del clasificador utilizado (pero con el mismo preprocesamiento).

Saha y Baumert [4] señalan que existen múltiples fenómenos ajenos a la actividad cerebral de interés, denominados *artefactos*, que añaden ruido a la señal capturada, y que la actividad cerebral generada en diferentes sesiones puede provocar diferencias significativas incluso en muestras pertenecientes al mismo sujeto. Además, la dificultad de adquirir este tipo de datos lleva a segmentar las grabaciones en ventanas o a generar datos sintéticos, y se ha mostrado que, en EEG, algunos procedimientos convencionales de partición de datos pueden representar una nueva forma de fuga de información que sobrestima el desempeño [5]–[7].

II. Trabajo relacionado

A. Fundamentos de teoría de la información

La teoría de la información fue desarrollada en 1948 por el matemático e ingeniero eléctrico Claude Shannon con la intención de estudiar el medio físico de la transmisión universal de señales [8]; sin embargo, su marco representa hoy en día un hito dentro de diversas ramas de estudio. Uno de los resultados derivados de este marco es la desigualdad de Fano [9], que acota el error mínimo alcanzable por cualquier estimador o clasificador en función de la información mutua entre las observaciones y la variable objetivo; Scarlett y Cevher [10] ofrecen una revisión moderna de sus aplicaciones en estimación estadística.

Conviene precisar, sin embargo, que la cota de Fano se define sobre la información mutua *poblacional* $I(X;Y)$, mientras que cualquier auditoría real solo dispone de un estimador de tamaño de muestra finito, calculado por un procedimiento con recursos computacionales acotados. Xu et al. [11] formalizan esta brecha con el concepto de *información usable* (*predictive $\mathcal{V}$-information*): la información que un observador de capacidad limitada, por ejemplo un clasificador entrenable con un número finito de datos, puede efectivamente extraer, la cual puede ser estrictamente menor que $I(X;Y)$. Esta distinción motiva que, en este trabajo, la estimación de $\hat{I}(X;Y)$ mediante el estimador KSG (descrito más adelante) se corrobore de forma independiente con clasificadores entrenados y validados empíricamente, en vez de reportar únicamente la cota derivada del estimador de información mutua.

B. Estado del arte en decodificación de habla imaginada

Lopez-Bernal et al. [12] presentan de forma exhaustiva una revisión de las técnicas empleadas en decodificación del habla imaginada con EEG, incluyendo técnicas de preprocesamiento,

extracción de características y clasificación, y destacan la heterogeneidad de vocabularios y de sus características.

Sobre los conjuntos de datos analizados en este trabajo (Sección II-E), la literatura reporta exactitudes que superan aparentemente al azar por un gran margen. En FEIS, Mahapatra y Bhuyan [13] alcanzan 89.01% de exactitud en la clasificación de los 16 fonemas mediante aprendizaje por transferencia con redes ResNet y DenseNet preentrenadas, mientras que Clayton et al. [14], con el mismo casco Emotiv EPOC+ de 14 canales, reportan un desempeño comparable con el de dispositivos EEG de grado de investigación al decodificar habla oída, imaginada y articulada. Sobre Kumar et al. [15], Tripathi [16] reporta 85.93%, 87.27% y 87.51% de exactitud para las tareas de dígitos, caracteres e imágenes respectivamente por medio de una arquitectura CNN-LSTM, mientras que Elwasify et al. [17] superan el 99% (99.38% en 30 clases) bajo un esquema de *random-split validation*, es decir, sin garantizar que las ventanas provenientes de una misma grabación continua de aproximadamente 12 segundos por (sujeto, clase) queden enteramente en los conjuntos de entrenamiento o de prueba. Los propios autores reportan que su exactitud baja a 95.25% al agrupar las ventanas por grabación (*GroupKFold*) y a 78.86% bajo LOSO. Sobre ArEEG_Chars, Darwish et al. [18] reportan 97% de exactitud con una red LSTM entrenada sobre subventanas de 250 ms recortadas de 930 grabaciones continuas de 10 s (39,857 sub-ventanas en total), una estructura de datos con el mismo riesgo de fuga por ventaneo dentro de la grabación. Para "Thinking out loud", Lopez-Bernal et al. [19] reportan 56.08% (k-NN) y 59.55% (SVM) usando coherencia inter-ensayo como característica, evaluando cada participante por separado con validación cruzada de 5 particiones; de forma análoga, sobre el conjunto Ruso-Español de palabras direccionales, Kostulin et al. [20], quienes introdujeron dicho conjunto, reportan $78\pm4\%$ con *Random Forest*, también evaluado por participante mediante validación cruzada de 5 particiones.

La dependencia del desempeño con respecto a la partición del dataset no es exclusiva del habla imaginada. La fuga de información es un modo de fallo extendido en la ciencia basada en aprendizaje automático: Kapoor y Narayanan [7] identifican al menos 294 artículos afectados en 17 disciplinas. En EEG, Brookshire et al. [5] muestran que dividir los datos por segmentos, de modo que segmentos de un mismo sujeto queden en entrenamiento y en prueba, sobrestima el desempeño en sujetos nuevos: en un modelo de clasificación de la enfermedad de Alzheimer, la exactitud cae de 99.8% con partición por segmentos a 53.0% con partición por sujeto, un valor indistinguible del azar. De forma análoga, Li et al. [6] muestran que, cuando los ensayos de entrenamiento y prueba provienen del mismo bloque temporal, los clasificadores aprovechan la autocorrelación temporal de la señal y no la actividad ligada al estímulo.

En la modalidad Leave-One-Subject-Out (LOSO), que deja todas las instancias de algunos sujetos en el conjunto de prueba, la exactitud disminuye considerablemente. Belfrouh et al. [21], en un estudio de más de 28,000 experimentos de transferencia entre sujetos sobre un conjunto de 15 sujetos y 5 clases, encuentran que la transferencia *zero-shot* entre sujetos se desempeña a nivel del azar, y que incluso con 25 minutos de calibración específica por sujeto la mejor configuración apenas alcanza 53.71% de exactitud.

C. Información mutua aplicada a señales EEG

La información mutua (MI) ha sido utilizada ampliamente para la decodificación del habla imaginada a partir de EEG, aunque principalmente empleada para la ingeniería de características: Tang et al. [22] proponen la selección de canales por medio de MI normalizada para interfaces cerebro-computadora (BCI por sus siglas en inglés). Más recientemente, Rao [23] estima la capacidad de información del EEG de forma teórica y computacional, y encuentra que el cuero cabelludo transmite del orden de decenas de bits por muestra sobre la actividad cortical subyacente y que dicha información satura alrededor de 64 a 128 electrodos. Este resultado motiva el análisis de cotas superiores de información, en lugar de depender únicamente de redes cada vez más grandes.

D. Estudio de confounds

En contraste con la teoría de la información aplicada a EEG, existe trabajo dedicado a analizar qué tan difícil es un problema de clasificación a partir de las propiedades del propio dataset. Lorena et al. [24] revisan 22 medidas estadísticas, entre ellas solapamiento de clases, linealidad, vecindad, estructura de red y dimensionalidad, todas ellas de índole geométrica sobre el espacio de características, sin considerar variables de confusión (*confounds*) ajenas a la tarea que puedan estar codificadas en los mismos datos.

La identidad del sujeto es un confound especialmente relevante en EEG, pues la señal contiene huellas individuales que permiten identificar a las personas con alta exactitud [25], [26], y la autocorrelación temporal puede actuar como otro confound dentro de una misma sesión [6]. La cuantificación de confounds ha sido abordada en el contexto de neuroimagen. Spisak [27] propone la *prueba de confusor parcial*, un test de permutación condicional que determina si las predicciones de un modelo dependen de una variable de confusión más allá de lo que su relación con la etiqueta objetivo modelaría. Hamdan et al. [28] encontraron, además, que remover el confound mediante regresión lineal sobre las características puede, contraintuitivamente, introducir una nueva fuga de información (*confound-leakage*) al combinarse con modelos no lineales, un riesgo que motiva medir el confound de forma directa antes de intentar removerlo.

E. Conjuntos de datos públicos de habla imaginada con EEG

Existen diferentes conjuntos de datos open-access para la decodificación de habla imaginada con EEG, cada uno con características de adquisición distintas. El conjunto FEIS (*Fourteen-channel EEG with Imagined Speech*) [29] registra 21 sujetos imaginando 16 fonemas del idioma inglés con un casco Emotiv EPOC+ de 14 canales. El conjunto "Thinking out loud" [30] (también llamado *Inner Speech*

Dataset) recoge 10 sujetos imaginando 4 direcciones (arriba/abajo/derecha/izquierda) con un sistema de 128 canales a 256 Hz, con múltiples sesiones y repeticiones por sujeto y por clase. Kumar et al. [15] introdujeron un conjunto de 23 sujetos con 30 clases (caracteres, dígitos e imágenes) capturado también con Emotiv EPOC+, aunque con una sola grabación por clase por sujeto; en este trabajo se analiza únicamente la subtarea de dígitos (10 clases), para la cual 21 de los 23 sujetos cuentan con grabaciones utilizables, cifras que se reflejan en las Tablas I–V. En la misma línea de caracteres individuales, Darwish et al. [18] introducen ArEEG_Chars, un conjunto de 30 sujetos imaginando las 31 letras del alfabeto árabe con un casco Emotiv EPOC X de 14 canales; Metwalli et al. [31] presentan, de forma independiente, un segundo conjunto de habla imaginada en árabe (ArEEG) con un vocabulario más reducido de 5 clases capturado con solo 8 electrodos, distinto del utilizado en este trabajo. Kostulin et al. [20] recogen, con un sistema de gel de 38 electrodos a 500 Hz, un conjunto bilingüe de 22 sujetos (12 hablantes nativos de ruso, 10 de español) que imaginan y articulan de forma encubierta entre 6 y 7 palabras direccionales, referido en este trabajo como "Inner-Speech Ruso-Español".

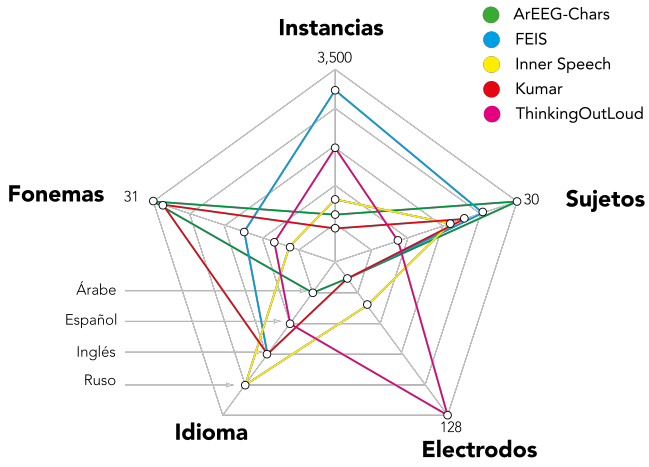


Fig. 1. Un gráfico de radar con las características de cinco datasets *open-access* distintos. Cada polígono representa un dataset. La figura muestra la diversidad de características en la generación de los datasets. Creación propia.

F. Desigualdad de procesamiento de datos

Dentro del desarrollo de algoritmos de IA es común aplicar procesamiento a los datos para mejorar el rendimiento de los modelos; sin embargo, existe un resultado clásico, la desigualdad de procesamiento de datos [32], según el cual la información obtenida tras aplicar algún procesamiento no puede superar a la original. Concretamente:

Teorema 1 (Desigualdad de procesamiento de datos)**.** *Si* $X \to Y \to Z$ *es una cadena de Markov, entonces* $I(X;Z) \leq I(X;Y)$.

Las implicaciones dentro de la IA de este resultado son mayúsculas, pues indica que aplicar un preprocesamiento a un atributo nunca producirá una información mutua poblacional mayor que la original. Como los conjuntos de datos son muestras de la población y los estimadores tienen sesgos, la desigualdad se cumple a nivel poblacional y no necesariamente para las estimaciones.

Una consecuencia central de este trabajo es que una cota calculada sobre una representación de dimensión reducida como las aplicadas en este estudio solo es válida para clasificadores que usen ese mismo pipeline de preprocesamiento.

G. Información mutua, estimador KSG y cota de Fano

La información mutua (MI) mide cuánta incertidumbre sobre una variable disminuye al conocer otra. Para variables discretas,

$$I(X;Y) = \sum_{x,y} p(x,y) \log_2 \frac{p(x,y)}{p(x)p(y)}, \tag{1}$$

Dado que las distribuciones conjunta y marginales se desconocen, se hace uso de estimadores; en este trabajo se emplea el estimador no paramétrico de Ross [33], extensión al estimador de Kraskov–Stögbauer–Grassberger [34], que en adelante se denomina KSG, dado por

$$\hat{I}(X;Y) = \psi(N) - \frac{1}{N}\sum_{i=1}^{N} \psi\left(N_{y_i}\right) + \psi(k) - \frac{1}{N}\sum_{i=1}^{N} \psi(m_i), \tag{2}$$

donde

- X es un vector de características e Y una etiqueta discreta.
- $N = |X|$ es la cantidad de instancias.
- $N_{y_i} = |\{\alpha \in Y : \alpha = y_i\}|$ es la cantidad de instancias con la misma etiqueta que la i-ésima.
- k es un parámetro que indica la cantidad de vecinos considerados por el algoritmo.
- $\psi(x) = \frac{d}{dx} \ln \Gamma(x)$ representa la función digamma.
- m_i se define por medio de ε_i como la distancia de x_i (la i-ésima instancia) a la k-ésima instancia más cercana de las que comparten la misma clase. Luego se define m_i como

  $$m_i = \left|\{x \in X : d(x_i, x) < \varepsilon_i\}\right|,$$

  es decir, la cantidad de instancias (de cualquier clase) que se encuentran a una distancia (siendo d una métrica adecuada) menor a ε_i.

La entropía de la clase Y está definida por

$$H(Y) = -\sum_{c=1}^{C} p(Y=c) \log_2 p(Y=c), \tag{3}$$

donde C representa la cantidad de clases distintas, nótese que para clases equiprobables

$$H(Y) = -\sum_{c=1}^{C} \frac{1}{C} \log_2 \frac{1}{C} = -\log_2 \frac{1}{C} = \log_2 C.$$

Sea $P_e = \Pr(\hat{Y} \neq Y)$ la probabilidad de error de un clasificador cualquiera de la variable X con respecto a Y. La desigualdad de Fano [9] establece que

$$H(Y|X) \leq H_b(P_e) + P_e \log_2(C-1),$$

donde H_b es la entropía binaria. Usando $H(Y|X) = H(Y) - I(X;Y)$ y $H(Y) = \log_2 C$ para clases equiprobables, el error mínimo P_e^* compatible con una información mutua $I = I(X;Y)$ es la solución de

$$H_b(P_e^*) + P_e^* \log_2(C-1) = \log_2 C - I \tag{4}$$

para $P_e^* \in \left[0, 1 - \frac{1}{C}\right]$, ecuación que se resuelve numéricamente dado que el lado izquierdo de la expresión es creciente en ese intervalo. El techo de exactitud es entonces

$$F = 1 - P_e^*(I). \tag{5}$$

De este modo, para $I = 0$ se obtiene $F = 1/C$ (el azar), y si $I = \log_2 C$ se obtiene $F = 1$. En este trabajo se descarta la cota habitual

$$F \leq \frac{I+1}{\log_2 C},$$

que resulta de acotar $H_b \leq 1$ y $\log_2(C-1) \leq \log_2 C$, porque de utilizarlo así aun con $I = 0$ da $1/\log_2 C > 1/C$ (50.0 % frente a 25.0 % para $C = 4$ y 20.2 % frente a 3.2 % para $C = 31$).

Una cantidad mayor de clases conlleva una complejidad mayor en la clasificación, por lo que el techo se normaliza respecto al azar y se pondera con un peso proveniente de los cálculos de significancia estadística. Concretamente:

$$F_Y = w_Y \left(\frac{F - \frac{1}{C}}{1 - \frac{1}{C}} \right) \in [0,1]. \tag{6}$$

El numerador indica la capacidad de F sobre el azar mientras que el denominador cuantifica el máximo posible sobre el azar. El valor $w_Y = 1 - p_Y$ está dado por el porcentaje de clasificaciones bajo permutación de etiquetas que no superan la clasificación de los datos reales (con el clasificador k-NN). De forma análoga se define $w_S = 1 - p_S$. w_Y se emplea únicamente como un factor heurístico de ajuste y no como una propiedad de la cota.

Como $\hat{I}$ se estima sobre una representación de dimensión reducida de la señal original, por el Teorema 1 subestima la información de la señal completa y, por tanto, F es un techo, en el mejor de los casos, para clasificadores que usen esa representación, no para cualquier clasificador del dataset, razón por lo cual este trabajo debe entenderse como un análisis de factibilidad en lugar de un límite demostrado.

H. Otros estadísticos

Con la finalidad de cuantificar la contaminación existente en los conjuntos de datos para decodificación del habla imaginada, se propone considerar en una misma fórmula la información aportada por la identidad del sujeto S y la aportada por la clase Y. La información que las observaciones X aportan sobre un atributo discreto es menor o igual que el logaritmo de su cantidad de valores: $I(X;Y) \in [0, \log_2 C]$ e $I(X;S) \in [0, \log_2 N_{\text{suj}}]$, donde N_{suj} es el número de sujetos. Por lo tanto,

$$\overline{I}(Y) = \frac{I(X;Y)}{\log_2 C}, \qquad \overline{I}(S) = \frac{I(X;S)}{\log_2 N_{\text{suj}}} \in [0,1].$$

Es posible definir entonces

$$CR = \frac{w_S \overline{I}(S)}{w_S \overline{I}(S) + w_Y \overline{I}(Y)} \in [0,1]$$

como la *razón de confusión* (*Confusion Ratio*, CR), un estadístico capaz de medir el nivel de contaminación existente en el dataset. Cuando $\overline{I}(S) \to 0$ entonces $CR \to 0$, y cuando $\overline{I}(Y) \to 0$ entonces $CR \to 1$; es decir, un menor valor de CR sugiere un conjunto con menos "huellas particulares" de cada sujeto en comparación con la información de clase. CR describe cuán dominante es la huella individual frente a la señal de clase, no la existencia de fuga.

Por último, con la finalidad de unificar todos los estadísticos auxiliares en una sola expresión se define el *coeficiente Fano-Confound* (CFC) como

$$CFC = \frac{F_Y}{1 + \max\{0, \operatorname{logit}(CR)\}}, \tag{7}$$

donde

$$\operatorname{logit}(x) = \ln \frac{x}{1-x}$$

es una función que ayuda a escalar la razón de confusión en valores más manejables. Se penaliza únicamente cuando $\operatorname{logit}(CR) > 0$, es decir, cuando $CR > 0.5$ y la huella del sujeto pesa más que la información de clase; este umbral es una convención y no se deriva de un criterio estadístico.

III. Metodología

Esta sección contiene los pasos que fueron seguidos para estimar los estadísticos Cota de Fano, sus variaciones y el estimador de Confound. Además de ello, se mencionan las referencias de donde fueron citadas los conceptos, ideas y ecuaciones para el cálculo de los coeficientes.

A. Intervalos de confianza

Para validar estadísticamente la significancia de los datos se implementó un algoritmo de muestreo que verifica la relevancia de las etiquetas; este consta de un muestreo aleatorio de algunas instancias de un mismo sujeto para posteriormente aplicar la medición del estimador de la información mutua y finalmente construir un intervalo de confianza mediante un bootstrap de 500 selecciones con repetición sobre los datos. El enfoque preciso se muestra en la Figura 3.

B. Cálculo de la información mutua

Para cada instante de tiempo t se calcula tanto la información mutua por canal como la información mutua conjunta entre los canales y la etiqueta. La primera suma la información mutua univariada de cada canal por separado, mientras que la segunda trata al vector de canales como una sola variable conjunta mediante el estimador KSG descrito anteriormente, permitiendo capturar la sinergia entre canales que la suma univariada ignora. El procedimiento se resume en el Algoritmo 2.

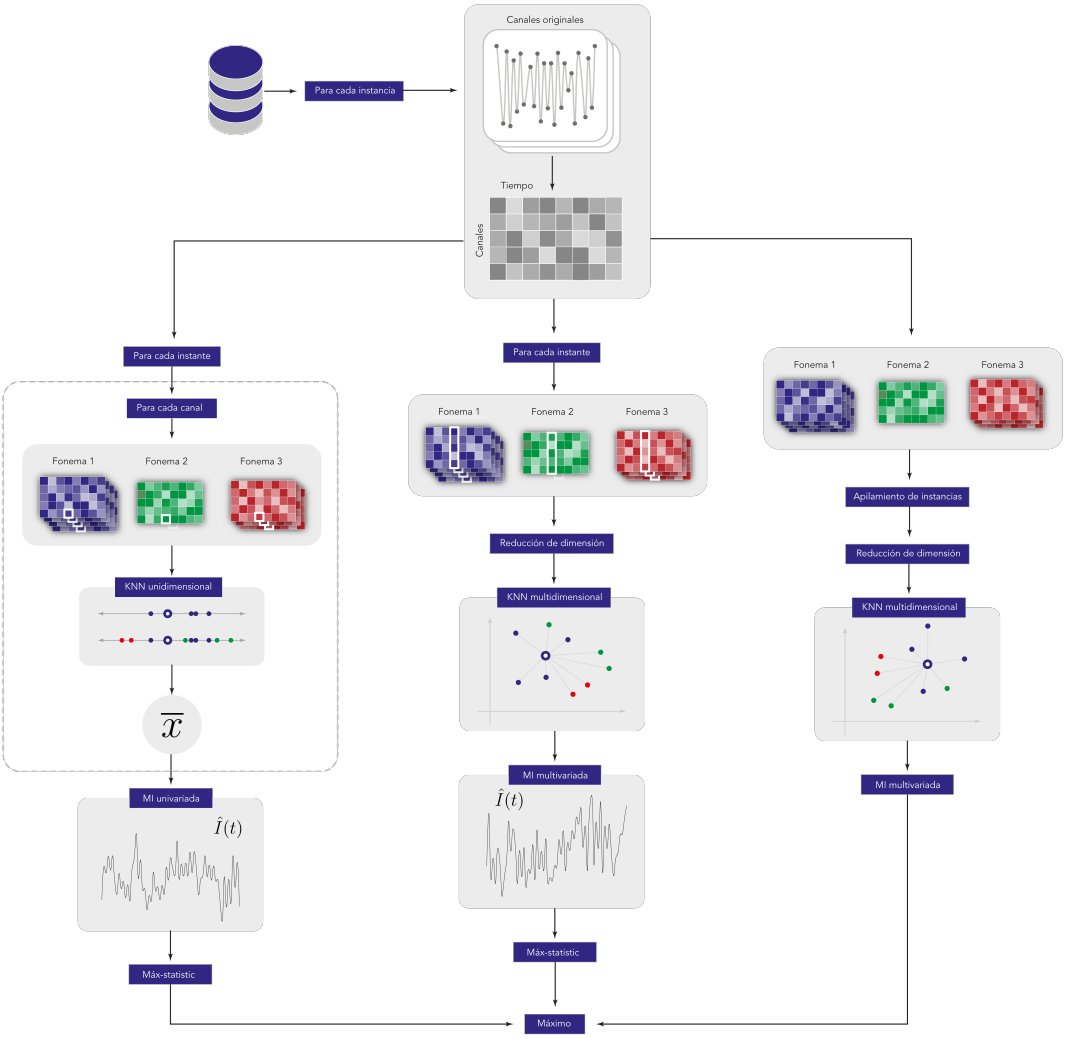


Fig. 2. Una instancia consta de una serie de tiempo por canal capturado y un fonema como etiqueta, puede pensarse como una imagen bidimensional donde cada fila representa un canal de EEG y cada columna un instante fijo del tiempo, En el gráfico se ilustra con un mismo color aquellas instancias pertenecientes a la misma clase. La estimación de MI se realiza por instante-canal por instante y por instancia, luego es elegido el mayor valor posible entre las tres opciones. Creación propia.

Algorithm 1 Intervalo de confianza de la MI por bootstrap

Require: Instancias X de un mismo sujeto; etiquetas Y; repeticiones $B = 500$
Ensure: Intervalo de confianza de $I(X;Y)$
1: **for** $b = 1$ **hasta** B **do**
2: Muestrear (X_b, Y_b) con reemplazo a partir de (X, Y)
3: $I_b \leftarrow I(X_b; Y_b)$
4: **end for**
5: Ordenar $\{I_1, \ldots, I_B\}$
6: $IC \leftarrow [\text{percentil}_{2.5}, \text{percentil}_{97.5}]$ de $\{I_b\}$
7: **return** IC

Algorithm 2 Cálculo de la MI por canal y la MI conjunta

Require: Muestras X con instantes de tiempo $t = 1, \ldots, T$ y canales $c = 1, \ldots, N_{ch}$; etiquetas Y
Ensure: $I_{canal}(t)$ e $I_{conjunta}(t)$ para cada instante t
1: **for** $t = 1$ **hasta** T **do**
2: $X_t \leftarrow$ valores de todos los canales en el instante t
3: **for** $c = 1$ **hasta** N_{ch} **do**
4: $I_c \leftarrow I(X_{t,c}; Y)$ ▷ MI univariada del canal c, estimador KSG
5: **end for**
6: $I_{canal}(t) \leftarrow \sum_{c=1}^{N_{ch}} I_c$
7: $I_{conjunta}(t) \leftarrow I(X_t; Y)$ ▷ MI conjunta sobre el vector de canales, estimador KSG multivariado
8: **end for**
9: **return** $\{I_{canal}(t)\}_{t=1}^{T}$, $\{I_{conjunta}(t)\}_{t=1}^{T}$

C. Análisis del ruido inmerso

Para detectar si los modelos que se entrenan con los datos citados en este artículo están detectando realmente los patrones comunes a cada fonema posible o si en vez de eso simple-

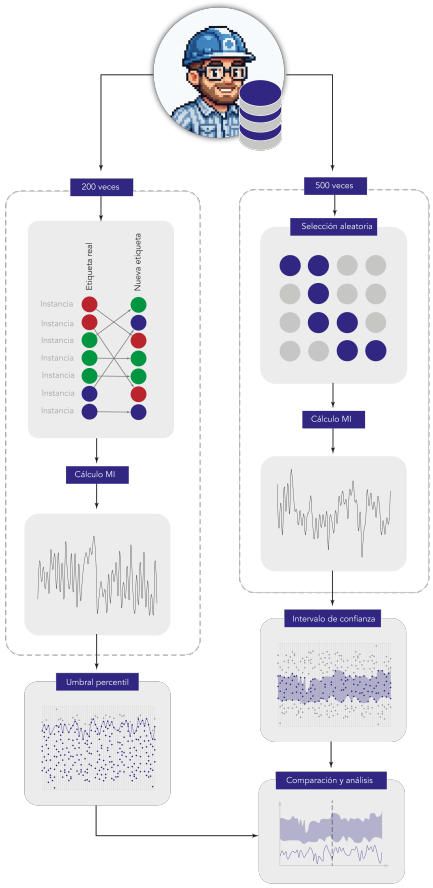


Fig. 3. Este diagrama describe el proceso en el cálculo de información para un mismo sujeto. Consta de dos ramas, de lado izquierdo se aplican permutaciones y se calcula la MI para finalmente aplicar un criterio de establecer como *umbral de ruido* a los puntos que se encuentran en el percentil 95. Del otro lado, se realiza un bootstrap de 500 ensayos para estimar un intervalo de confianza con 95%.

mente detectan falsos patrones en el ruido se implementó un algoritmo cuyo propósito es detectarlo bajo el siguiente procedimiento:

Algorithm 3 Umbral de ruido por permutación

Require: Muestras X con instantes de tiempo $t = 1, \ldots, T$; etiquetas Y; número de permutaciones N_{perm}
Ensure: Umbral de ruido θ_t para cada instante t

```
for i = 1 hasta N_perm do
    Y_i ← permutación aleatoria de las etiquetas Y
    for t = 1 hasta T do
        I_i(t) ← I(X_t; Y_i)            ▷ MI en el instante t
    end for
end for
for t = 1 hasta T do
    θ_t ← percentil_95({I_1(t), I_2(t), ..., I_{N_perm}(t)})
end for
return {θ_t}_{t=1}^T
```

Para visualizar mejor el algoritmo descrito anteriormente el lector puede consultar la Figura 2.

D. Significancia estadística

Para corroborar que la clasificación tiene sentido se optó por aplicar una técnica denominada prueba de permutación, la cual consiste en intercambiar las etiquetas de las instancias y aplicar un clasificador simple en los nuevos datos; posteriormente se compara el rendimiento (exactitud en este caso) del clasificador sobre los datos originales y los datos con las etiquetas intercambiadas. El proceso se repite N_{perm} veces y se mide el porcentaje p de ensayos donde el desempeño en los datos falsos es mayor o igual que en los datos originales (véase [35] sobre la corrección $(r+1)/(N+1)$ de este valor p).

Es claro que al aplicar un clasificador simple el desempeño no será competitivo; sin embargo, funciona como un buen indicador y generalmente cuenta con una baja latencia, permitiendo aplicar una cantidad considerable de muestras aleatorias. En este trabajo se utilizaron como clasificadores *k-Nearest Neighbors* (k-NN) basado en la idea de proximidad de las instancias como puntos de $\mathbb{R}^n$ y *Logistic Regression* (LR), un algoritmo que no se basa en distancias entre instancias (aunque, con regularización, depende de la escala de las características, por lo que éstas se estandarizan).

Idealmente, todos los ensayos con las etiquetas permutadas deberían tener un desempeño modesto en comparación con la clasificación de las instancias originales, siendo esto una prueba empírica de que existe un patrón (explícito o implícito) en las instancias pertenecientes a la misma categoría.

Se mide la significancia con respecto a dos variables, el fonema o clase, la cual se denotará como Y y el atributo que indica el sujeto del cual ha sido capturada la muestra S.

IV. Resultados

En esta sección se enuncian los estadísticos calculados según las fórmulas mostradas en secciones previas. Se aplican dos criterios distintos en todas las variantes, primero en el dominio temporal (original) y posteriormente en el dominio de la frecuencia por medio del método de Welch.

Cuando fue posible se aplicaron sobre tres métodos de validación distintos: intra-sujeto, inter-sujeto y LOSO, además de analizar de forma independiente la información del sujeto y de la clase de las instancias.

Como sugiere la teoría, el método intra-sujeto, al ser la media de los estadísticos calculados independientemente sobre las instancias de cada sujeto, representa un mejor desempeño que la validación inter-sujeto debido a que el algoritmo no debe generalizar en reglas aplicables a diferentes personas sino encontrar patrones en las instancias de un mismo sujeto. Por otro lado, en casi todos los casos la información obtenida de la validación inter-sujeto tiene mejor resultado que la validación LOSO debido a que esta intenta aplicar reglas obtenidas en varios sujetos sobre las instancias de un nuevo individuo.

La Tabla I no permite calcular el techo de Fano intra-sujeto para Kumar y ArEEG_Chars porque estos datasets solo cuentan con una instancia por cada sujeto y clase, además,

TABLE I
TECHOS DE FANO DE LA ETIQUETA DE CLASE.

			Temporal			Espectral			F_Y normalizado (%)	
Dataset	C	Azar (%)	Intra-sujeto (%)	Inter-sujeto (%)	LOSO (%)	Intra-sujeto (%)	Inter-sujeto (%)	LOSO (%)	Temporal	Espectral
ArEEG_Chars	31	3.2	—	5.6	8.9	—	3.2	5.3	1.0	0.0
FEIS	16	6.25	18.4	14.3	16.8	—	6.2	6.2	5.9	0.0
InnerSpeechRuEs	6	16.7	45.4	30.7	28.2	39.0	28.3	23.0	16.8	13.9
Kumar	10	10.0	—	21.3	17.4	—	10.0	19.3	1.7	0.0
ThinkingOutLoud	4	25.0	44.7	41.3	39.4	36.3	31.6	34.3	20.4	2.0

TABLE II
TECHO DE FANO DE IDENTIDAD DE SUJETO.

Dataset	N_{suj}	Azar (%)	Temporal (%)	Espectral (%)
ArEEG_Chars	30	3.3	54.9	85.7
FEIS	21	4.8	57.2	95.3
InnerSpeechRuEs	22	4.5	50.4	88.8
Kumar	21	4.8	35.6	98.0
ThinkingOutLoud	10	10.0	66.0	100.0‡

TABLE III
SIGNIFICANCIA ESTADÍSTICA DE ETIQUETA DE CLASE.

			Temporal		Espectral	
Dataset	C	Azar (%)	k-NN (%, p)	LR (%, p)	k-NN (%, p)	LR (%, p)
ArEEG_Chars	31	3.2	2.4 (0.579)	2.7 (0.765)	0.9 (1.000)	1.3 (1.000)
FEIS	16	6.25	6.8 (0.314)	6.8 (0.022)	5.3 (0.884)	5.3 (0.889)
InnerSpeechRuEs	6	16.7	19.4 (<0.001)	18.4 (0.017)	20.4 (<0.001)	20.1 (0.011)
Kumar	10	10.0	9.0 (0.864)	9.0 (0.752)	1.4 (1.000)	2.4 (1.000)
ThinkingOutLoud	4	25.0	26.9 (0.065)	26.4 (0.201)	23.9 (0.775)	23.8 (0.797)

TABLE IV
SIGNIFICANCIA ESTADÍSTICA DE IDENTIDAD DE SUJETO.

			Temporal		Espectral	
Dataset	N_{suj}	Azar (%)	k-NN (%, p)	LR (%, p)	k-NN (%, p)	LR (%, p)
ArEEG_Chars	30	3.3	29.1 (<0.001)	31.3 (<0.001)	77.5 (<0.001)	76.9 (<0.001)
FEIS	21	4.8	28.9 (<0.001)	17.0 (<0.001)	89.3 (<0.001)	93.9 (<0.001)
InnerSpeechRuEs	22	4.5	27.2 (<0.001)	19.4 (<0.001)	78.9 (<0.001)	89.4 (<0.001)
Kumar	21	4.8	22.9 (<0.001)	22.9 (<0.001)	92.9 (<0.001)	98.6 (<0.001)
ThinkingOutLoud	10	10.0	37.2 (<0.001)	42.3 (<0.001)	99.8 (<0.001)	99.8 (<0.001)

TABLE V
COEFICIENTES DE FANO-CONFOUND

	Temporal				Espectral			
Dataset	CR (%)	F_Y (%)	logit(CR)	CFC (%)	CR (%)	F_Y (%)	logit(CR)	CFC (%)
ArEEG_Chars	100.0	1.0	13.82	0.07	100.0	0.0	13.82	0.00
FEIS	97.3	5.9	3.57	1.29	100.0	0.0	13.82	0.00
InnerSpeechRuEs	88.8	16.8	2.07	5.47	97.1	13.9	3.50	3.09
Kumar	97.9	1.7	3.85	0.35	100.0	0.0	13.82	0.00
ThinkingOutLoud	90.3	20.4	2.23	6.30	99.8	2.0	6.32	0.28

realizar *windowing* sobre esa muestra insertaría un nuevo sesgo en las nuevas instancias, el de las condiciones de la sesión en que fue capturada la muestra.

Con la inversión exacta de la desigualdad de Fano, el techo de exactitud de la etiqueta supera al azar (el recíproco de la cantidad de clases) por entre 0 y 28.7 puntos porcentuales según el conjunto y la partición, y la ventaja es mayor en las particiones intra-sujeto que en inter-sujeto y LOSO. En cuatro de las diez celdas espectrales inter-sujeto y LOSO (ArEEG_Chars, FEIS y Kumar con inter-sujeto, y FEIS con LOSO), y en ninguna del dominio temporal, $\hat{I}(X;Y) = 0$ y el techo coincide exactamente con el azar (Tabla I). Con la cota

laxa $(I+1)/\log_2 C$, el superávit aparente sería de 17.0 a 34.5 puntos porcentuales, y una parte sustancial de él sería el propio sesgo de la relajación (por ejemplo, 20.2 % frente a 3.2 % para ArEEG_Chars con $\hat{I} = 0$). El dominio espectral tampoco representa en general una mejora sobre el temporal al estimar la información de la etiqueta; la única excepción, marginal, es Kumar con LOSO (19.3 % frente a 17.4 %). El techo intra-sujeto de ThinkingOutLoud, por ejemplo, corresponde a $\hat{I} \approx 0.13$ bits y equivale a 44.7 % de exactitud con la inversión exacta, y no a 56.6 % como indicaría la cota laxa.

Con respecto al método de cálculo de MI se tiene que $Y \to X \to X_t \to X_{t,c}$, por el Teorema 1 se tiene que

$$I\left(X_{t,c}; Y\right) \leq I\left(X_t; Y\right) \leq I\left(X; Y\right),$$

La literatura muestra que existen bandas de frecuencia con más información; sin embargo, a consecuencia del Teorema 1, aplicar un filtrado de frecuencia no aumenta la información contenida en las instancias. En el caso de dominios (temporal y de frecuencia) no es posible establecer dicha relación debido a que esas relaciones no constituyen una cadena de Markov, razón por la cual fueron analizados de forma independiente.

La Tabla II fue calculada de forma similar al cálculo de MI para clasificación de la identidad de sujeto; además, corrobora claramente que la información del sujeto en el dominio espectral de las instancias es completamente clasificable, es decir, cada individuo del dataset cuenta con patrones únicos que lo distinguen de los demás claramente, lo cual es consistente con la literatura sobre huellas neurofisiológicas individuales [25], [26]. Puede observarse un incremento considerable en la clasificación en el dominio de la frecuencia.

Para la cota de Fano de la identidad de sujeto es imposible aplicar los métodos de validación; sin embargo, es claro que la cota de Fano de la identidad de sujeto es ampliamente mayor a la de clase en todos los métodos, lo cual puede indicar un sesgo en los algoritmos de clasificación.

Con respecto a la significancia estadística, la Tabla III muestra que los clasificadores simples no superan significativamente el azar, en ninguno de los dos dominios, para ArEEG_Chars, Kumar y ThinkingOutLoud ($p \geq 0.065$), ni para FEIS salvo la regresión logística temporal ($p = 0.022$, una prueba entre veinte sin corrección por comparaciones múltiples). La única excepción robusta es InnerSpeechRuEs, donde ambos clasificadores detectan señal en ambos dominios ($p < 0.001$ con k-NN en los dos, y $p = 0.017$ y $p = 0.011$ con LR en el dominio temporal y espectral, respectivamente), aunque su exactitud excede al azar en apenas 2 a 4 puntos porcentuales y discrepa del resultado de KSG con corrección por estadístico máximo, que no es significativo. En ArEEG_Chars y Kumar en el dominio espectral, la totalidad de las permutaciones iguala o supera a los datos originales ($p = 1.000$) y en FEIS espectral lo hace $88\,\%$ de ellas. Por último, la clasificación sobre el dominio de la frecuencia solo supera a la del dominio original en InnerSpeechRuEs; en los otros cuatro conjuntos es inferior, lo que coincide con la ausencia de mejora al estimar la información.

Para el caso de la significancia de sujeto se puede observar en la Tabla IV que en todos los casos (espectral y temporal) clasificar las instancias con las etiquetas permutadas jamás supera a la clasificación de los sujetos reales, lo cual sugiere que los sujetos tienen patrones muy marcados dentro de los datos. Por otro lado, algo a destacar es que clasificar los sujetos aun con algoritmos simples permite obtener muy buenos resultados, incluso apenas por debajo del 100% en el caso del dominio espectral de ThinkingOutLoud.

A. *Exactitud por debajo del azar*

La Tabla III contiene un resultado que el ruido no explica: en el dominio espectral, Kumar (1.4 % con k-NN, azar de 10 %) y ArEEG_Chars (0.9 %, azar de 3.2 %) obtienen exactitudes consistentemente *inferiores* al azar, con $p = 1.000$. Son los dos conjuntos con una única grabación por par (sujeto, clase) y, a la vez, aquellos en que el sujeto se identifica con mayor claridad en el dominio espectral (Tabla IV). Al evaluar dejando una instancia fuera, el vecino más cercano de una instancia casi siempre es otra instancia del mismo sujeto, cuya etiqueta es por construcción distinta. Si q es la probabilidad de que el vecino más cercano sea del mismo sujeto y, en caso contrario, la etiqueta coincide con probabilidad $1/C$, entonces

$$\text{exactitud} \approx \frac{1-q}{C}.$$

Tomando q como la exactitud con k-NN de la identidad de sujeto (92.9 % en Kumar y 77.5 % en ArEEG_Chars), el modelo predice 0.7 % en ambos conjuntos frente a los 1.4 % y 0.9 % observados. Es la evidencia más directa, en este trabajo, de que la huella del sujeto domina la geometría del espacio de características, y no solo de que sea clasificable.

V. Trabajo futuro

La metodología utilizada en este trabajo es robusta y obtiene resultados consistentes con la literatura con datasets en el sentido de mejores cotas para los datasets con mejores clasificaciones. Sin embargo, existen variaciones a estos que pueden representar una mejora en el trabajo realizado. En el caso de la reducción de dimensionalidad se utiliza en todo momento PCA por su capacidad para mantener la varianza de las características originales, pero pueden aplicarse otros métodos como *information gain* o *Linear Discriminant Analysis*.

En el algoritmo KSG, por practicidad, debido a su baja latencia, en este trabajo se optó por utilizar $k = 3$, pero es posible elegir cualquier otro valor de k al hacer las estimaciones. Asimismo, el propio método para el cálculo de MI fue un estimador no paramétrico basado en una aproximación numérica, una alternativa más robusta podría ser aplicar estimadores paramétricos o no paramétricos distintos. Otro hecho a destacar es que el tiempo de ejecución de estos algoritmos es considerablemente menor al entrenamiento de redes neuronales profundas, lo cual indica que podría ser preferible comparar las cotas CFC para distintas arquitecturas en lugar de entrenarlas a todas incrementando el tiempo de cómputo.

Por último, debe considerarse que la identidad de sujeto no constituye la única forma de fuga de datos, otros trabajos pueden enfocarse en el análisis estadístico del *windowing* o la generación de datos sintéticos.

VI. Conclusiones

Con la inversión exacta de la desigualdad de Fano, el techo de exactitud de la clase sobre una representación reducida de la señal excede al azar por a lo sumo 28.7 puntos porcentuales y, en cuatro celdas espectrales, coincide con él; por otro lado, la identidad de sujeto es casi perfectamente clasificable y, en los conjuntos con una sola grabación por (sujeto, clase), produce exactitudes por debajo del azar.

Agradecimientos

Agradecemos a la Universidad Nacional Autónoma de México (UNAM) por permitirnos ejecutar los programas enunciados en este artículo dentro del clúster de supercómputo Ken del Laboratorio Nacional de Visualización Científica Avanzada (LAVIS).

Asimismo, expresamos nuestra gratitud hacia la Secretaría de Ciencia, Humanidades, Tecnología e Innovación (SECIHTI) por el financiamiento realizado al posgrado en Inteligencia Artificial de la Universidad Autónoma de Querétaro (UAQ).

Los autores declaran no tener conflictos de interés relevantes al contenido de este artículo.

References

[1] Z. C. Lipton and J. Steinhardt, "Troubling trends in machine learning scholarship," *ACM Queue*, vol. 17, no. 1, 2019.

[2] C. A. E. Goodhart, "Problems of monetary management: The u.k. experience," Reserve Bank of Australia, Tech. Rep., 1975.

[3] D. Manheim and S. Garrabrant, "Categorizing variants of Goodhart's law," 2019.

[4] S. Saha and M. Baumert, "Intra- and inter-subject variability in EEG-based sensorimotor brain computer interface: A review," *Frontiers in Computational Neuroscience*, vol. 13, p. 87, 2020.

[5] G. Brookshire, J. Kasper, N. M. Blauch, Y. C. Wu, R. Glatt, D. A. Merrill, S. Gerrol, K. J. Yoder, C. Quirk, and C. Lucero, "Data leakage in deep learning studies of translational EEG," *Frontiers in Neuroscience*, vol. 18, p. 1373515, 2024.

[6] R. Li, J. S. Johansen, H. Ahmed, T. V. Ilyevsky, R. B. Wilbur, H. M. Bharadwaj, and J. M. Siskind, "The perils and pitfalls of block design for EEG classification experiments," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 43, no. 1, 2021.

[7] S. Kapoor and A. Narayanan, "Leakage and the reproducibility crisis in machine-learning-based science," *Patterns*, vol. 4, no. 9, p. 100804, 2023.

[8] C. E. Shannon, "A mathematical theory of communication," *The Bell System Technical Journal*, vol. 27, no. 3, pp. 379–423, 1948.

[9] R. M. Fano, *Transmission of Information: A Statistical Theory of Communication*. Cambridge, MA: MIT Press, 1961.

[10] J. Scarlett and V. Cevher, "An introductory guide to fano's inequality with applications in statistical estimation," in *Information-Theoretic Methods in Data Science*. Cambridge University Press, 2021, arXiv:1901.00555.

[11] Y. Xu, S. Zhao, J. Song, R. Stewart, and S. Ermon, "A theory of usable information under computational constraints," in *International Conference on Learning Representations (ICLR)*, 2020, arXiv:2002.10689.

[12] D. Lopez-Bernal, D. Balderas, P. Ponce, and A. Molina, "A state-of-the-art review of EEG-based imagined speech decoding," *Frontiers in Human Neuroscience*, vol. 16, p. 867281, 2022.

[13] N. C. Mahapatra and P. Bhuyan, "Decoding of imagined speech electroencephalography neural signals using transfer learning method," *Journal of Physics Communications*, vol. 7, no. 9, p. 095002, 2023.

[14] J. Clayton, S. Wellington, C. Valentini-Botinhao, and O. Watts, "Decoding imagined, heard, and spoken speech: Classification and regression of EEG using a 14-channel dry-contact mobile headset," in *Proc. Interspeech 2020*, 2020, pp. 4886–4890.

[15] P. Kumar, R. Saini, P. P. Roy, P. K. Sahu, and D. P. Dogra, "Envisioned speech recognition using EEG sensors," *Personal and Ubiquitous Computing*, vol. 22, pp. 185–199, 2018.

[16] A. Tripathi, "Analysis of EEG frequency bands for envisioned speech recognition," 2022.

[17] F. Elwasify, E. Shaaban, and R. M. Abdelmoneem, "EEG imagined speech neuro-signal preprocessing and deep learning classification," *Scientific Reports*, vol. 16, p. 10604, 2026.

[18] H. Darwish, A. Al Malah, K. Al Jallad, and N. Ghneim, "ArEEG_Chars: Dataset for envisioned speech recognition using EEG for Arabic characters," 2024.

[19] D. Lopez-Bernal, D. Balderas, P. Ponce, and A. Molina, "Exploring inter-trial coherence for inner speech classification in EEG-based brain–computer interface," *Journal of Neural Engineering*, vol. 21, no. 2, p. 026048, 2024.

[20] D. V. Kostulin, P. D. Shaposhnikov, A. K. Ekizyan, I. G. Shevchenko, D. G. Shaposhnikov, I. V. Shcherban, and V. N. Kiroy, "EEG-based brain-computer interface (BCI) dataset for directional word recognition," *Scientific Data*, vol. 13, p. 1195, 2026.

[21] S. Belfrouh, R. Errattahi, and F. Z. Salmam, "Rapid calibration for cross-subject imagined speech decoding toward restoring communication," in *Proc. Odyssey 2026, The Speaker and Language Recognition Workshop*, 2026, pp. 144–150.

[22] C. Tang, D. Jiang, L. Dang, and B. Chen, "EEG decoding based on normalized mutual information for motor imagery brain–computer interfaces," *IEEE Transactions on Cognitive and Developmental Systems*, vol. 16, no. 6, pp. 1997–2007, 2024.

[23] I. Rao, "Information capacity of EEG: Theoretical and computational limits of recoverable neural information," arXiv:2510.17841, 2025.

[24] A. C. Lorena, L. P. F. Garcia, J. Lehmann, M. C. P. Souto, and T. K. Ho, "How complex is your classification problem? a survey on measuring classification complexity," *ACM Computing Surveys*, vol. 52, no. 5, p. 107, 2019.

[25] M. Demuru and M. Fraschini, "EEG fingerprinting: Subject-specific signature based on the aperiodic component of power spectrum," *Computers in Biology and Medicine*, vol. 120, p. 103748, 2020.

[26] J. da Silva Castanheira, H. D. Orozco Perez, B. Misic, and S. Baillet, "Brief segments of neurophysiological activity enable individual differentiation," *Nature Communications*, vol. 12, p. 5713, 2021.

[27] T. Spisak, "Statistical quantification of confounding bias in machine learning models," *GigaScience*, vol. 11, p. giac082, 2022.

[28] S. Hamdan, B. C. Love, G. G. von Polier, S. Weis, H. Schwender, S. B. Eickhoff, and K. R. Patil, "Confound-leakage: Confound removal in machine learning leads to leakage," *GigaScience*, vol. 12, p. giad071, 2023.

[29] S. Wellington and J. Clayton, "Fourteen-channel EEG with imagined speech (FEIS) dataset," Zenodo, 2019.

[30] N. Nieto, V. Peterson, H. L. Rufiner, J. E. Kamienkowski, and R. Spies, "Thinking out loud, an open-access EEG-based BCI dataset for inner speech recognition," *Scientific Data*, vol. 9, p. 52, 2022.

[31] D. Metwalli, A. E. Kiroles, Y. A. Radwan, E. A. Mohamed, M. Barakat, A. Ahmed, A. M. Omar, and S. Selim, "ArEEG: an open-access arabic inner speech EEG dataset," *Scientific Data*, vol. 12, p. 1513, 2025.

[32] T. M. Cover and J. A. Thomas, *Elements of Information Theory*, 2nd ed. Wiley-Interscience, 2006.

[33] B. C. Ross, "Mutual information between discrete and continuous data sets," *PLoS ONE*, vol. 9, no. 2, p. e87357, 2014.

[34] A. Kraskov, H. Stögbauer, and P. Grassberger, "Estimating mutual information," *Physical Review E*, vol. 69, no. 6, p. 066138, 2004.

[35] B. Phipson and G. K. Smyth, "Permutation p-values should never be zero: Calculating exact p-values when permutations are randomly drawn," *Statistical Applications in Genetics and Molecular Biology*, vol. 9, no. 1, p. Article 39, 2010.